

Proyectos II, integración y preparación de datos

DATA MEETS HOME



JORGE ACÍN ZURITA

MIHAI CRISTIAN MIHALACHE FARCAS

ROBERT TORRES MINGARRO

RUBÉN TORMO PILES

ÍNDICE

1.	Alcance del proyecto.....	3
2.	Configuración del proyecto	4
3.	Resultados obtenidos	6
	3.1 Comparar la influencia de las características de una vivienda sobre su precio entre 2018 y 2025.....	6
	3.2 Estudiar la evolución del precio de la vivienda en diferentes distritos de Valencia	9
	3.3 Analizar y determinar el modelo estadístico que ofrezca la mejor predicción del valor de las viviendas en Valencia durante el año 2018	11
	3.4 Evaluar la capacidad predictiva del modelo de 2018 en la actualidad y ajustar las predicciones en base a la evolución del Índice de Precios de la Vivienda (IPV).	14
4.	Privacidad y legalidad de los datos	17
5.	Anexos	18
	5.1 HITOS.....	18
	5. 2 Limpieza 2018.....	18
	5. 3 Limpieza 2025.....	18
	5. 4 Objetivo 1	18
	5.4.1 PCA.....	18
	5.4.2 Regresión lineal y correlaciones	18
	5. 5 Objetivo 2	18
	5.5.1 Justificación del uso de distritos.....	18
	5.5.2 Justificación de los rangos de precio empleados	19
	5.5.3 Distribución de pisos por rango de precio y distrito 2018 y 2025.....	20
	5.5.4 Intento de PCA previo clustering 2018.....	22
	5.5.5 Matrices de distancias y estadístico de Hopkins 2018	22
	5.5.6 Clustering 2018.....	24
	5.5.7 Clustering 2025.....	24
	5.5.8 Clústeres formados	24
	5.6 Objetivo 3	25
	5.6.1 Correlación entre las variables	25
	5.6.2 Modelos predictivos.....	25
	5.6.3 Modelos predictivos con clustering.....	32
	5.7 Objetivo 4	35
	5.7.1 IPV	35

1. Alcance del proyecto

Nuestro proyecto, llamado “*Data Meets Home*” trata de analizar la evolución del mercado inmobiliario en **el centro** de Valencia entre los años 2018 y 2025, centrándose en cómo distintas características de las viviendas influyen en su precio y cómo dicha influencia ha variado a lo largo del tiempo.

A partir de esto, queremos llegar a entender y predecir el precio de una vivienda en Valencia en función de sus características, lo que podría ser útil tanto para futuros compradores y vendedores como para profesionales del sector inmobiliario.

1.1. Objetivos del proyecto

OBJETIVO 1: Comparar la influencia de las características de una vivienda sobre su precio entre 2018 y 2025.

OBJETIVO 2: Estudiar la evolución del precio de la vivienda en diferentes distritos de Valencia.

OBJETIVO 3: Analizar y determinar el modelo estadístico que ofrezca la mejor predicción del valor de las viviendas en Valencia durante el año 2018.

OBJETIVO 4: Evaluar la capacidad predictiva del modelo de 2018 en la actualidad y ajustar las predicciones en base a la evolución del Índice de Precios de la Vivienda (IPV).

1.2. Utilidad del estudio

Este estudio puede resultar especialmente útil para diferentes perfiles. Por un lado, los compradores y vendedores particulares pueden utilizar los resultados para tomar decisiones más informadas en el proceso de compraventa. Por otro, los profesionales del sector inmobiliario, como agentes o tasadores, pueden apoyarse en el análisis para realizar valoraciones más precisas y ajustadas al contexto actual.

Asimismo, lograría ayudar a personas que no tienen altos conocimientos del mercado inmobiliario. De esta forma tendrían un apoyo para estimar el precio de compra/venta de una vivienda.

Por lo tanto, *Data Meets Home* puede llegar a proporcionar una mejor y más detallada visión del sector inmobiliario en el municipio de Valencia, permitiendo entender qué factores influyen más en la evolución de los precios y como estos han ido evolucionando.

2. Configuración del proyecto

2.1. Fuentes de datos

Para el desarrollo de este proyecto se han utilizado tres fuentes de datos principales:

IDEALISTA 2018

Esta base de datos contiene información detallada sobre viviendas en la ciudad de Valencia en el año 2018, incluyendo características como número de habitaciones, superficie, presencia de garaje, cercanía a puntos de interés, entre otras. Estos datos permiten analizar los factores que influían en el precio de la vivienda en ese momento.

La extracción de la base de datos se realizó a través de [este repositorio](#) en *GITHUB*. Al ser un archivo .RDA, simplemente había que cargar el *dataframe*.

API IDEALISTA (2025)

A través del acceso a la API oficial de Idealista, se ha recopilado una base de datos actualizada con características similares a las del conjunto de 2018. Esta fuente permite comparar directamente el mercado actual con el de hace siete años, evaluando cambios en los precios y en la relevancia de distintas variables.

La extracción como bien acabamos de comentar, se realizó gracias al acceso que nos proporcionó *Idealista* de su API oficial. Empleando un programa que creamos en *Python*, obtuvimos un .json con los datos que posteriormente se transformó a .xlsx (Excel) y trabajó a partir de él en R.

IPV (Índice de Precios de Vivienda)

Esta fuente proporciona datos oficiales sobre la evolución del precio medio de la vivienda en España, lo que permite contextualizar los resultados obtenidos a partir de Idealista. Gracias al IPV, es posible observar las tendencias generales del mercado inmobiliario desde 2018 hasta la actualidad.

Por último, los datos del IPV se consiguieron a través de la página del INE. Trabajamos a partir del .xlsx que nos proporcionan al descargar los datos.

Obtendremos una información más detallada sobre las bases de datos y sus características en el documento del [anexo-hito1](#).

2.2. Integración y transformación de los datos

IDEALISTA 2018

Nuestra base de datos IDEALISTA_2018 contenía muchas filas repetidas y viviendas donde se había actualizado alguna información, ya que la misma vivienda se volvía a subir repetidas veces, seguramente por no llegar a venderse y el anunciante decidía disminuir el precio. Por ello, hemos decidido quedarnos con la vivienda de menor precio (en caso de haber filas repetidas).

Proyectos II, integración y preparación de datos

Posteriormente decidiríamos eliminar columnas de variables no relevantes para el estudio o con gran número de faltantes, además de eliminar los datos anómalos.

Asimismo, creamos una nueva variable `RHabitacion_Baño`, para obtener la ratio de habitaciones por cada baño y añadir información al estudio. ([limpieza 2018](#))

IDEALISTA 2025

A lo largo del proceso se ha trabajado con un conjunto de datos inmobiliarios de Valencia para el año 2025, que presentaba una estructura relativamente compleja debido a la integración de información procedente de diferentes fuentes y formatos. La calidad inicial de los datos era aceptable, aunque se detectaron duplicados derivados del solapamiento en el scraping, así como variables anidadas en formato JSON y presencia de valores ausentes o inconsistentes en algunas columnas.

La limpieza realizada incluyó la eliminación de duplicados, la extracción y transformación de variables relevantes desde campos JSON, la depuración de columnas constantes o irrelevantes y el tratamiento de valores anómalos tanto en variables numéricas como categóricas. Se corrigieron inconsistencias en variables clave como la distancia al centro y el número de planta, y se imputaron valores faltantes mediante técnicas apropiadas. Además, se aplicó un análisis de componentes principales (PCA) para detectar y eliminar observaciones multivariantes atípicas.

La integración de los datos requirió un esfuerzo considerable, especialmente en la normalización de formatos y la conversión de variables complejas a estructuras tabulares manejables. Las transformaciones básicas incluyeron la recodificación de variables categóricas y binarias, la imputación de valores faltantes y la estandarización de unidades y formatos. Gracias a este proceso, se obtuvo un conjunto de datos depurado, homogéneo y adecuado para el análisis estadístico y la modelización predictiva. ([limpieza 2025](#))

IPV (Índice de Precios de Vivienda)

No ha sido necesaria la limpieza de los datos del IPV, ya que el archivo únicamente contenía dos variables: el trimestre y el valor del índice. Por tanto, simplemente se ha realizado el pivotado de los datos para obtener la serie temporal deseada, sin requerir pasos adicionales de depuración o transformación.

Obtendremos una información más detallada sobre las características en el documento del [anexo-hito2](#).

3. Resultados obtenidos

3.1 Comparar la influencia de las características de una vivienda sobre su precio entre 2018 y 2025

El precio de una vivienda depende en gran medida de sus propias características, como la superficie, el número de habitaciones, la existencia de ascensor o el estado de conservación. Sin embargo, la influencia de estas variables puede cambiar con el tiempo, reflejando nuevas prioridades del mercado o transformaciones en el contexto urbano. Es por esto por lo que queremos analizar cómo ha sido este cambio en la influencia de estas características entre 2018 y 2025 en Valencia.

El primer paso que hemos decidido realizar es un PCA de las variables numéricas de ambas bases de datos para tener una idea general de las características de las viviendas. Después de todo el proceso realizado, que podemos ver en el siguiente [anexo](#), obtenemos las siguientes conclusiones a partir de la visualización:

2018:




Gráfico 3.1.1: PCA 2018




Gráfico 3.1.2: PCA 2018

2025:




Gráfico 3.1.3: PCA 2025




Gráfico 3.1.4: PCA 2025

Proyectos II, integración y preparación de datos

En ambos análisis, las variables relacionadas con las características físicas de la vivienda, como el número de habitaciones, superficie y número de baños aparecen consistentemente como principales contribuyentes a las primeras componentes. Esto indica que estos factores han sido estructuralmente determinantes en la configuración del valor de las viviendas en ambos periodos.

Además, la variable precio, aunque se ha tratado como suplementaria, mantiene una alineación clara con las variables estructurales de la vivienda en ambos años. Esto refuerza la idea de que el precio está más influenciado por aspectos como tamaño, número de estancias o baños, que por otros factores. Otra cosa que podemos observar es que variables relacionadas con la ubicación o accesibilidad muestran una dirección opuesta a la de las variables estructurales, reflejando su relación inversa con el precio y tamaño: cuanto mayor la distancia, menor es el valor o calidad de la vivienda.

Por último, en el PCA de 2025 aparecen nuevas variables como priceByArea o numPhotos, que no estaban presentes en 2018. Algunas, como priceByArea, muestran un comportamiento particular y contribuyen significativamente a componentes diferentes, lo que podría estar relacionado con cambios en cómo se percibe el valor por metro cuadrado o con nuevas formas de marketing digital (por ejemplo, la cantidad de fotos en un anuncio).

El segundo paso sería terminar de analizar las diferencias que hay entre la influencia de las variables comunes en ambas bases de datos sobre el precio entre los dos años. Para esto, haremos uso de modelos de regresión lineal y de correlaciones de Pearson.

De esta forma, observaremos qué variables están más correlacionadas con el precio y como cambia esta importancia de 2018 a 2025:

Todo este proceso lo tenemos mejor explicado en el siguiente [anexo](#).

A partir de los modelos y de los gráficos de correlaciones que podemos observar aquí, obtenemos los siguientes resultados:




Gráfico 3.1.5: CORRELACIONES 2018
CORRELACIONES 2018




Gráfico 3.1.6:

El análisis comparativo entre 2018 y 2025 revela un cambio relevante en los factores que más inciden sobre el precio de la vivienda en Valencia, reflejando tanto una

Proyectos II, integración y preparación de datos

transformación en las preferencias de los compradores como una evolución del propio mercado inmobiliario.

En primer lugar, se observa una disminución generalizada en la fuerza de las correlaciones de muchas variables clásicamente asociadas al valor de un inmueble, como la superficie construida, el número de baños o la presencia de ascensor. Aunque estas variables siguen siendo importantes, su impacto marginal en el precio se ha reducido. Esto puede estar vinculado a una mayor homogeneización del parque inmobiliario: a medida que más viviendas incorporan ciertos estándares de confort (como ascensor o varios baños), dejan de ser elementos claramente diferenciales que impulsen el precio.

Por ejemplo, la superficie construida, que en 2018 era el principal determinante del precio con una correlación de 0.76, pierde fuerza en 2025 (0.58), aunque se mantiene como el factor más influyente. Este descenso puede sugerir una saturación del mercado respecto al tamaño: una vivienda más grande no garantiza un precio proporcionalmente más alto si no viene acompañada de otros atributos de calidad o eficiencia energética. De forma similar, el número de baños pierde peso como símbolo de confort, lo que podría indicar una normalización de ciertas comodidades en las viviendas más modernas.

Por el contrario, variables que capturan la calidad del diseño interior, como la proporción entre habitaciones y baños (`RHabitacion_Banyo`), aumentan ligeramente su influencia. Esto sugiere que los compradores actuales valoran cada vez más la funcionalidad y equilibrio en la distribución de espacios, más allá de simples métricas cuantitativas. Este cambio puede ser indicativo de una mayor sofisticación en las decisiones de compra, especialmente en mercados urbanos donde el espacio es limitado y caro.

En cuanto a la ubicación, los patrones se mantienen relativamente estables. La distancia al centro urbano continúa teniendo una relación negativa clara con el precio, lo que demuestra que la centralidad sigue siendo una ventaja competitiva en términos de valor inmobiliario. Sin embargo, el impacto de la distancia al metro se suaviza, lo que podría explicarse por una mejora global del transporte público o por una diversificación en los medios de movilidad (como bicicletas, scooters, autobuses más eficientes o incluso el teletrabajo), reduciendo la dependencia exclusiva del metro como criterio clave de accesibilidad.

Finalmente, estos resultados sugieren que el mercado está evolucionando hacia un modelo más complejo, en el que ya no basta con tener una vivienda grande o bien equipada, sino que se valoran otros elementos como el diseño interior, la eficiencia funcional, la sostenibilidad o la conectividad urbana. Esta transición obliga tanto a promotores como a compradores y administraciones públicas a reconsiderar qué atributos definen realmente el valor de una vivienda en un contexto contemporáneo.

Proyectos II, integración y preparación de datos

3.2 Estudiar la evolución del precio de la vivienda en diferentes distritos de Valencia

El municipio de Valencia es una zona que, inmobiliariamente hablando, cada día que pasa se encuentra más cotizada y exigida, año tras año, el precio sigue aumentando en la *terreta*. Una de las preguntas que nos puede surgir es si en todos los distritos el precio ha evolucionado de la misma forma, las características en cada distrito son similares o en cambio son heterogéneos, estas son algunas de las dudas que resolveremos a continuación empleando las bases de datos de Idealista de 2018 y 2025.

Para poder estudiar las variables que influyen sobre cada piso dependiendo del distrito en el que se encuentre, deberemos de seguir diversos pasos y técnicas que nos llevarán a poder lograrlo.

Primeramente, asignaremos a cada vivienda su debido barrio. Gracias a emplear un documento con los polígonos de los barrios y las latitudes y longitudes de las casas, podremos asignarles su barrio correspondiente. Asimismo, agruparemos los barrios en distritos. [\(1\)](#)

Posteriormente, para facilitar nuestro análisis crearemos una nueva variable `RANGO_PRECIO`, que clasifique las viviendas en 3 tipos, Barato-Medio-Caro. Es decir, discretizaremos la variable precio. De esta forma nos será más sencillo determinar que características presentan los pisos de cada distrito dependiendo del `RANGO_PRECIO` donde se encuentren, de la misma manera, no aplanaremos la base de datos y conservaremos las cualidades de las viviendas, dependiendo del intervalo de precios.

Para determinar los intervalos realizaremos un histograma para cada año (2018 y 2025) y sus resúmenes estadísticos. [\(2\)](#)

Analizaremos la distribución de pisos en los distritos según su rango de precios. De esta forma determinaremos como se caracterizan los distritos y los cambios de 2018 respecto a 2025. [\(3\)](#)

Ulteriormente, vamos a crear un *dataframe* que para cada distrito las medias, mínimos, máximos y desviaciones típicas de cada variable, sobre cada rango de precio. Esto se realiza para evitar aplanar la base de datos y juntar todos los tipos de pisos, así podemos conservar las diferencias y variabilidad entre ellos.

Por otra parte, nuestro siguiente paso será la realización del clustering, así conseguiremos fácilmente agrupar distritos con características similares, y de esta manera explicarlos a todos conjuntamente.

Primeramente, intentaríamos realizar un PCA, para comprobar si de esta manera el clustering se realizaría de mejor manera. No obstante, tras realizarlo y comparar resultados llegamos a la conclusión de no emplear PCA previo al clustering. No aportaba grandes diferencias y solamente dificultaba obtener resultados y conclusiones. [\(4\)](#)

Previo a la realización del clustering, hemos decidido comprobar las matrices de distancias y el estadístico de Hopkins, para comprobar la tendencia de agrupamiento. [\(5\)](#)

Proyectos II, integración y preparación de datos

Procedemos a la realización del clustering para 2018 ⁽⁶⁾ y 2025 ⁽⁷⁾. Como podemos apreciar, decidimos coger 5 clústers y 4 respectivamente para 2018 y 2025, ambos con el método de k-medias.

Los clústers formados ⁽⁸⁾ responden bastante a la situación geográfica de los distritos, no obstante, algún que otro clúster puede llegar a sorprendernos. Se agrupan de manera similar, no obstante, al contar con 1 clúster menos y haber pasado 7 años, hay diferencias en los distritos agrupados, así como en sus características.

No obstante, pese a haber pasado los años, el factor diferencial sigue siendo el precio por m². Así como el ratio de baños por habitación, y el ascensor o estado del piso no tienen relevancia alguna. Por otra parte, ha ganado mucho peso diferenciando los clústers las distancias al centro y al metro, posible signo de buscar pisos más céntricos y mejor comunicados para optimizar y ahorrar el tiempo.

Valencia: Distritos coloreados por Cluster
Clusters k-means




Gráfico 3.2.1: Mapa 2de Clústeres Valencia 2018

Valencia: Distritos coloreados por Cluster
Clusters k-means




Gráfico 3.2.2: Mapa 1de Clústeres Valencia 2025

Entre 2018 y 2025, los distritos centrales como **Ciutat Vella** y **L'Eixample** han pasado de ser heterogéneos a concentrar **nueva construcción y polarización inmobiliaria**, reflejo claro de **gentrificación y centrificación**. Barrios como **Benicalap** o **Quatre Carreres** han caído en clusters con peor distribución y dotación, son barrios menos buscados y con peores condiciones que el resto.

Zonas como **Algirós** o **L'Olivereta** muestran un perfil más envejecido y menos modernizado en 2025, son viviendas en su mayor estado de segunda mano, perdiendo protagonismo en el mercado especulativo.

Finalmente, el mercado parece haberse reorganizado en torno a **cuatro perfiles más definidos**, reduciendo la complejidad observada en 2018. No obstante, la distribución pese a haber pasado 7 años y todos los cambios que ello ha conllevado, sigue siendo muy similar.

3.3 Analizar y determinar el modelo estadístico que ofrezca la mejor predicción del valor de las viviendas en Valencia durante el año 2018

Tras una fase inicial de limpieza de datos y análisis exploratorio que incluyó la caracterización de clústeres por distrito, se centra en el desarrollo y la evaluación de un modelo predictivo robusto para el precio de la vivienda en Valencia. El objetivo principal es no solo alcanzar una alta precisión en las predicciones utilizando datos de 2018, sino también identificar los factores más influyentes en la determinación del precio, con la perspectiva de aplicar la metodología desarrollada a conjuntos de datos futuros, como el de 2025.

Para la consecución de este objetivo, se ha utilizado exclusivamente el conjunto de datos de Idealista correspondiente al año 2018. Esta decisión se fundamenta en su mayor volumen de registros, lo que facilita el entrenamiento de modelos más robustos y con mejor capacidad de generalización. Si bien se consideró el conjunto de datos de 2025, su limitado número de observaciones impidió el desarrollo de modelos capaces de explicar adecuadamente la variabilidad del mercado inmobiliario en esa muestra.

Las variables que utilizaremos para el modelo son similares a las de los clústers pero hay algún cambio. Usaremos “ASSETID” (para identificar solamente, no se tendrá en cuenta para entrenar los modelos), “FLOORCLEAN”, “PRICE”, “CONSTRUCTEDAREA”, “ROOMNUMBER”, “BATHNUMBER”, “DISTRITO”, “DISTANCE_TO_CITY_CENTER”, “DISTANCE_TO_METRO”, “HASLIFT”, “BUILDTYPEID_1”, “BUILDTYPEID_2” y “BUILDTYPEID_3”. No tenemos en cuenta variables como *RHabitacion_Banyo* y *priceByArea* ya que al ser variables derivadas directamente de *price/size* o *rooms/bathrooms* generaría fuga de información. No añadirían información nueva y pueden generar multicolinealidad¹.

Hay varias variables que hemos tenido que transformar o modificar para poder trabajar con ellas. En primer caso, “FLOORCLEAN” presentaba valores faltantes, al ser una variable que consideramos importante para el estudio y haber cerca de un 3,5% de valores faltantes, hemos decidido imputarlos por la mediana. Hemos juntado las 3 variables “BUILDTYPEID_X” de tal forma que hemos creado una nueva llamada “status” que sintetiza la información. Las variables categóricas “status” y “DISTRITO” se transformaron mediante la técnica *one-hot-encoding* generando variables *dummys* para su inclusión en los modelos. Finalmente hemos creado una nueva variable llamada “LOGPRICE” aplicándole el logaritmo en base 10 al valor del precio que usaremos en algunos modelos con el fin de ... mejorar la predicción. Comprobamos la correlación que existe entre las variables para evitar problemas de colinealidad en el [gráfico](#).

Para alcanzar el objetivo de predicción, se entrenaron y evaluaron los siguientes algoritmos de regresión en el entorno de R: Regresión Lineal, Random Forest, XGBoost y LightGBM. Además, con el fin de mejorar los resultados, en algunos casos hemos tenido que ajustar los hiperparámetros de los modelos correspondientes como en el Random Forest o aplicar técnicas como eliminar el 5% de los *outliers* por arriba ya que

¹ La multicolinealidad es un problema que puede surgir en los modelos de regresión lineal cuando dos o más variables independientes (predictoras) están altamente correlacionadas entre sí. Es decir, una variable independiente puede predecirse en gran medida a partir de otra.

Proyectos II, integración y preparación de datos

no son casas comunes y se salen de la media. También hemos utilizado en algunos modelos la transformación logarítmica de la variable “PRICE” para reducir su asimetría y hacer la distribución se asemeje más a una normal. Estos son los resultados que hemos obtenido (podemos obtener información más detallada en el siguiente [anexo](#)):

Tabla Resumen del Rendimiento de los Modelos de Predicción de Precios

Modelo	RMSE (€)	MAE (€)	R ²	Notas
Regresión Lineal	100403,39	60231,54	0,6708	Modelo base
Regresión Lineal (Filtrado)	301750,4	52096,88	0,2511	Mejor MAE que sin filtrado pero peor R ²
Random Forest (Inicial)	67660,69	32814,38	0,8509	Mejora sustancial sobre la Regresión Lineal
Random Forest (Optimizado)	66644,44	32860,48	0,8556	Ligera mejora sobre el RF inicial
XGBoost	70004,63	34858,91	0,8402	Buen rendimiento, pero no supera al RF Optimizado
LightGBM	72355,27	39014,97	0,8293	Rendimiento similar a XGBoost
Random Forest (Filtrado)	38747,33	25343,29	0,836	Mejora el RF inicial Percentil 95% y LOGPRICE

Tabla 3.3.1: Tabla con los resultados obtenidos para el RMSE, MAE y R² para los distintos modelos predictivos entrenados.

Si observamos los resultados obtenidos, vemos como el Random Forest destaca frente al resto, en especial el entrenado con el logaritmo del precio y la eliminación de los *outliers*. Obtenemos un error medio absoluto de 25343€ que destaca frente al resto y un R² de 0,836, ligeramente inferior a la del Random Forest inicial, que explica gran parte de la variabilidad del conjunto de datos. Podemos observar que los puntos parecen agruparse más densamente alrededor de la línea de ajuste perfecto (roja discontinua), especialmente en los rangos de precios más bajos y medios. Esto es consistente con la mejora en RMSE y MAE. La dispersión sigue aumentando para los precios más altos dentro de este rango filtrado, lo cual es un comportamiento típico.

El análisis de importancia de variables para este modelo destaca CONSTRUCTEDAREA como el factor más influyente, seguido por BATHNUMBER, DISTANCE_TO_CITY_CENTER y HASLIFT. Esto indica que, dentro del rango de precios más común, el tamaño, el número de baños, la proximidad al centro y la disponibilidad de ascensor son clave.

Proyectos II, integración y preparación de datos




Gráfico 3.3.1: Gráfico de dispersión de precios reales vs. precios predichos por el modelo Random Forest para la base de 2018 utilizando el LOGPRICE y el percentil 95 .




Gráfico 3.3.2: Gráfico de barras con la importancia de las variables para el modelo de Random Forest para la base de 2018 utilizando el LOGPRICE y el percentil.

Por último, hemos decidido crear modelos basándonos en los clústeres obtenidos previamente. Primero para la variante con 5 clústeres y a continuación, para 2 clústeres, uno de con los distritos del centro y otro con los distritos de la periferia. Ninguno de ellos ha obtenido mejores resultados que los modelos previos así que nos quedamos con los anteriores para intentar predecir el valor de 2025. Podemos obtener más información en el siguiente [anexo](#).

En conclusión, para poder obtener un modelo mejor nos haría falta tener en cuenta más variables, sobre todo en los pisos caros ya que son las que marcan la diferencia. Nuestras bases de datos carecen de esa información y por ello no podemos obtener un mejor resultado. No obstante, un MAE de 25k€ aproximadamente es bastante sólido y es buen predictor.

3.4 Evaluar la capacidad predictiva del modelo de 2018 en la actualidad y ajustar las predicciones en base a la evolución del Índice de Precios de la Vivienda (IPV).

En este apartado se pretende analizar hasta qué punto un modelo predictivo entrenado con datos de 2018 es capaz de estimar los precios actuales de la vivienda en Valencia. Para ello, se evaluará el rendimiento del modelo al aplicarlo sobre datos recientes y se comprobará si existe un desfase significativo entre las predicciones y los valores reales. En caso de observarse una diferencia relevante, se propone ajustar las predicciones originales utilizando la evolución del Índice de Precios de la Vivienda (IPV) como factor de corrección, con el objetivo de aproximar las estimaciones del modelo a la realidad actual del mercado.




Gráfico 3.4.1: Gráfico de dispersión de precios reales vs. precios predichos por el modelo Random Forest para los datos de 2025.

Las primeras predicciones del modelo, entrenado con datos de 2018, no han reflejado correctamente los precios actuales de la vivienda en Valencia. Esto se evidencia en los resultados obtenidos al evaluar el modelo sobre datos recientes, donde se observa un error cuadrático medio (RMSE) de 317.013,40 € y un error absoluto medio (MAE) de 213.572,30€. Estos valores indican que existe un desfase significativo entre las estimaciones del modelo y los valores reales del mercado, lo que se corrobora visualmente en el gráfico de dispersión. Por ello, se va a realizar un pequeño análisis exploratorio del Índice de Precios de la Vivienda (IPV), con el objetivo de observar cómo han evolucionado los precios desde 2018 hasta 2025. Este análisis permitirá ajustar las predicciones del modelo a la situación actual del mercado, mejorando así su precisión.

Primero observaremos la evolución año a año desde 2007 hasta 2024 para tener una visión global de la situación del mercado inmobiliario.

Proyectos II, integración y preparación de datos

El gráfico [\(4\)](#) muestra claramente la evolución del Índice de Precios de la Vivienda (IPV) en la Comunidad Valenciana desde 2007 hasta 2024. En este periodo se aprecia una fuerte caída de precios entre 2008 y 2013, seguida de una fase de estabilización y, a partir de 2016, una recuperación progresiva que se intensifica especialmente desde 2020. Como resultado, en 2024 los precios alcanzan máximos históricos, superando los niveles previos a la crisis y reflejando la actual fase de expansión del mercado inmobiliario en la región.

Ahora miraremos la evolución entre 2018 (datos con los que se ha entrenado el modelo) y 2024 más detalladamente, por trimestre ya que son las que nos interesan.




Gráfico 3.4.2: Evolución trimestral del Índice de Precios de la Vivienda (IPV) en la Comunidad Valenciana (2018-2024)

A partir del gráfico de la evolución trimestral del Índice de Precios de la Vivienda (IPV) en Valencia entre 2018 y 2024, se observa una tendencia claramente ascendente y sostenida en el valor del IPV. Tras un crecimiento moderado en los primeros años, a partir de 2021 el incremento se vuelve mucho más pronunciado, especialmente en los últimos trimestres, donde el IPV alcanza sus valores máximos históricos.

Esta evolución confirma que el mercado inmobiliario ha experimentado un importante encarecimiento desde 2018, lo que explica por qué un modelo entrenado con datos antiguos subestima sistemáticamente los precios actuales. Por tanto, resulta imprescindible ajustar las predicciones del modelo teniendo en cuenta esta fuerte subida del IPV, ya que refleja el cambio real en el valor de la vivienda durante este periodo. Así, el análisis del IPV justifica y fundamenta la necesidad de corregir las estimaciones del modelo para alinearlas con la situación actual del mercado.

Proyectos II, integración y preparación de datos




Gráfico 3.4.3: Gráfico de dispersión de precios reales vs. precios predichos por el modelo Random Forest y corregidos por el IPV.

Tras aplicar la corrección basada en la evolución del IPV, observamos que tanto el RMSE como el MAE del modelo disminuye notablemente hasta situarse en torno a 235.000 € y 145.000 € respectivamente, lo que indica una mejora significativa en la precisión de las predicciones. Además, en el gráfico de dispersión se aprecia claramente cómo el desfase entre los precios reales y los predichos se ha reducido considerablemente, alineando mucho mejor las estimaciones del modelo con los valores actuales del mercado. Esto demuestra la eficacia del ajuste por el IPV para adaptar el modelo a la realidad de 2025.

A pesar de la mejora tras el ajuste por el IPV, el modelo sigue presentando un error medio elevado. Esto se debe, en parte, a la complejidad inherente del mercado inmobiliario, especialmente cuando se intenta predecir con una diferencia temporal de siete años, periodo en el que han cambiado significativamente la influencia de muchas variables relevantes como se ha visto en el objetivo 3.1. Además, el alto valor absoluto del error está influido por el propio precio medio de la vivienda en Valencia, que ha alcanzado máximos históricos en los últimos años (el precio medio de los datos de 2025 es de 440000€). Por todo ello, aunque la corrección mejora la precisión, sigue siendo necesario interpretar los resultados del modelo con cautela y considerar sus limitaciones en un contexto de mercado tan dinámico y cambiante.

Para ver más en detalle [ANEXO HTML](#)

4. Privacidad y legalidad de los datos

Por último, la adquisición y uso de datos para el proyecto ha estado condicionada por consideraciones de privacidad y legalidad, lo que ha influido directamente en el alcance y los objetivos del estudio. Por un lado, el acceso a información actualizada y detallada estuvo limitado por las políticas de protección de datos y las restricciones impuestas por los proveedores de datos, como Idealista. La necesidad de solicitar acceso a una API oficial, con permisos restringidos y cuotas de uso, dificultó la obtención de un volumen de datos representativo y completamente actualizado para el año 2025.

Estas limitaciones legales y de privacidad han supuesto que algunos objetivos iniciales del proyecto tuvieran que ser replanteados o ajustados. Por ejemplo, no fue posible realizar comparativas exhaustivas entre 2018 y 2025 con la granularidad deseada, ni incorporar variables adicionales que podrían haber enriquecido el análisis predictivo. Como hemos comentado anteriormente, pensamos que con unas bases de datos más completas hubiésemos sido capaces de obtener un mejor modelo predictivo que hubiese sido capaz de explicar más porcentaje de variabilidad de los precios.

En definitiva, el respeto a la normativa vigente y la ética en el tratamiento de los datos han sido prioritarios, aunque ello haya supuesto una reducción en la cantidad y calidad de la información disponible y, por tanto, en el alcance de las conclusiones del estudio.

5. **Anexos**

5.1 HITOS

Enlace a una carpeta con el HITO 1 y el HITO 2:

[HITOS 1 Y 2](#)

5. 2 Limpieza 2018

<https://rpubs.com/mcmihala/limpieza2018>

5. 3 Limpieza 2025

<https://rpubs.com/roberttorres/1315191>

5. 4 Objetivo 1

5.4.1 PCA

Encontramos más información en: [anexo](#)

5.4.2 Regresión lineal y correlaciones

Encontramos más información en: [anexo](#)

5. 5 Objetivo 2

5.5.1 Justificación del uso de distritos

En Valencia hay más de 80 barrios, pero solo 19 distritos. Usar distritos reduce la complejidad y mejora la visualización y comunicación de resultados. Además, **los distritos son divisiones oficiales del ayuntamiento de Valencia**, utilizadas en censos, estadísticas urbanas, presupuestos municipales, etc. Seguir esta estructura permite que nuestros análisis sean comparables con fuentes oficiales.

Proyectos II, integración y preparación de datos

5.5.2 Justificación de los rangos de precio empleados

Observando los histogramas, a primera vista puede parecer que la distribución es la misma, no obstante, simplemente apreciando los valores de los precios, nos damos cuenta de la diferencia abismal que hemos ido acumulando durante estos últimos 7 años.





Gráfico 2: Histograma de precios de viviendas 2025.

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
24000	97000	148000	195036	228000	2772000

Gráfico 3: Summary de los precios de viviendas 2018.

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
26800	217000	330000	445873	550000	4700000

Gráfico 4: Summary de precios de viviendas 2025.

Por ende, lo más lógico es que cada año tenga diferentes rangos de precio, una vivienda “barata” en 2025 no lo sería en el año 2018.

Año 2018: Después de haber analizado minuciosamente el histograma y el resumen estadístico de la variable PRICE, hemos decidido dividir los rangos de precio de la siguiente forma:

- **Barato: < 100.000 €.** Se ajusta aproximadamente al 1er cuartil (97.000 €). Es más, el histograma muestra una enorme acumulación de viviendas con precios por debajo de 100.000 €. Incluye las viviendas más accesibles del mercado.

- **Medio: 100.000 € – 300.000 €:** Aquí se concentra la mayor parte del mercado, y donde el volumen comienza a caer gradualmente a partir de los 300k€. Cubre el rango entre el 1er y algo más allá del 3er cuartil (228.000 €). Incluye la mediana (148.000 €) y la mayoría del stock disponible. Refleja el mercado “normal” o promedio.

- **Caro: > 300.000 €:** Representa pisos por encima del rango común. A partir de los 300.000 €, la frecuencia en el histograma cae en picado. Es un indicio claro de que estamos entrando en el segmento de lujo o alto standing.

Año 2025: habiendo realizado el histograma y resumen estadístico correspondiente, procederemos a justificar la división de precios actual:

- **Barato ≤ 250.000 €:** Este rango abarca todos los precios hasta ligeramente por encima del 1er cuartil (217.000 €), este grupo representa el segmento más asequible y frecuente. Además, gran parte de los valores están concentrados en dicha zona, tal y como se aprecia en el histograma.

Proyectos II, integración y preparación de datos

- Medio 250.001 – 550.000 €: Este rango contiene la mediana (330.000 €), por lo que representa el valor central del mercado. El 2º y 3º cuartil (Q2 y Q3) están dentro de este rango, abarcando el 50% central de las viviendas. Justo 550.000 € es el tercer cuartil, hace de límite con el segmento más alto del mercado.

- Caro > 550.000 €: Todo lo que supera el Q3 (550k) se considera de elevado precio, y está respaldado por la asimetría positiva del histograma (claramente sesgada hacia la derecha). Aunque hay viviendas extremadamente caras (hasta 4,7 millones), son muy poco frecuentes.

5.5.3 Distribución de pisos por rango de precio y distrito 2018 y 2025

Para ello nos apoyaremos en estas tablas, contando con el número de pisos para cada distrito por intervalo de precios (2018).

DISTRITO <chr>	Barato <int>	Medio <int>	Caro <int>
Algirós	180	692	26
Benicalap	940	819	66
Benimaclet	69	481	65
Camins al Grau	40	320	258
Campanar	100	579	277
Ciutat Vella	50	1109	950
El Pla del Real	18	489	480
Extramurs	97	1695	368
Jesús	466	329	5
L'Eixample	23	1009	1011

1-10 of 16 rows

DISTRITO <chr>	Barato <int>	Medio <int>	Caro <int>
L'Olivereta	845	1099	18
La Saïdia	1146	1086	80
Patraix	822	2083	38
Poblat Marítims	1068	1768	77
Quatre Carreres	651	1789	137
Rascanya	784	729	88

Tabla 1: Tabla con nº de pisos por distrito y rango de precio 2018.

- Distritos con mayoría de pisos baratos: La Saïdia (1146), Poblat Marítims (1068), Benicalap (940) y L'Olivereta (845) tienen una gran cantidad de pisos de bajo coste. Son zonas con una importante oferta de vivienda económica. Nos sugiere que son zonas más asequibles, donde predomina la vivienda de clase trabajadora/media, además de situarse en la periferia

- Distritos con mayoría de pisos medios: Patraix (2083), Quatre Carreres (1789), Poblat Marítims (1768), Extramurs (1695) y L'Eixample (1009) presentan una alta concentración en el segmento medio, indicando posiblemente una mezcla equilibrada de calidad, ubicación y accesibilidad.

- Distritos con abundancia de pisos caros: L'Eixample (1011), Ciutat Vella (950) y El Pla del Real (480) destacan por una elevada cantidad de viviendas caras. Era algo que

Proyectos II, integración y preparación de datos

nos podíamos esperar, debido a que son zonas céntricas y muy prestigiosas de Valencia que cuentan con bastantes viviendas de alto standing.

- Distritos donde encontramos una presencia importante de los tres rangos (Barato, Medio, Caro): Camins al Grau, Campanar, Benimaclet, Poblats Marítims y Rascanya muestran una variedad de precios, esto se traduce en que podemos encontrar pisos para cualquier bolsillo y presupuesto.

Vamos a analizar y comparar los cambios y similitudes en la tendencia de los pisos entre 2018 y 2025. Nos apoyaremos también en una tabla contando con el número de pisos para cada distrito por intervalo de precios.

district <chr>	Barato <int>	Medio <int>	Caro <int>
Algirós	21	48	10
Benicalap	58	41	11
Benimaclet	8	19	8
Camins al Grau	88	90	68
Campanar	34	54	62
Ciutat Vella	40	114	201
El Pla del Real	7	21	55
Extramurs	32	108	86
Jesús	87	69	4
L'Eixample	5	123	216

district <chr>	Barato <int>	Medio <int>	Caro <int>
L'Olivereta	119	31	5
La Saïdia	67	40	10
Patraix	79	69	8
Poblats Marítims	211	123	63
Quatre Carreres	66	174	46
Rascanya	139	33	1

Tabla 2: Tabla con nº de pisos por distrito y rango de precio 2025.

- Distritos con mayoría de pisos baratos tanto en 2018 como en 2025: Poblats Marítims, sigue destacando con mayoría de pisos baratos. Por su parte, Benicalap y Rascanya, se siguen manteniendo como zonas con mayoría de pisos a bajo coste, aunque con una leve subida de pisos con precio medio.
- Distritos que han ganado peso en rango medio: Quatre Carreres, pasa de una mezcla bastante equilibrada a una clara predominancia del rango medio. Camins al Grau, mantiene una distribución muy equilibrada en 2025, lo que sugiere estabilidad de perfil mixto.
- Distritos que refuerzan su perfil caro: L'Eixample, en 2018 ya tenía una gran cantidad de pisos caros, y en 2025 sigue siendo el distrito con más proporción de pisos caros (216 frente a solo 5 baratos). Ciutat Vella, aumenta su polarización ya que en 2025 hay más pisos caros que en cualquier otra categoría. El Pla del Real, continúa con más caros que medios o baratos.
- Distritos que cambian de perfil: Jesús, en 2018 tenía mayoría de pisos baratos (466) y pocos caros (5). En 2025 esa proporción se invierte: aunque siguen predominando los baratos, el porcentaje de medios ha crecido mucho.

Proyectos II, integración y preparación de datos

Extramurs, pasa de ser muy medio (1695) a una distribución más equilibrada en 2025 entre medio y caro.

Conclusión general de la comparación:

Mantienen perfil barato: Poblat Marítims, Benicalap, Rascanya

Mantienen perfil caro: L'Eixample, Ciutat Vella, Pla del Real

Transición hacia el rango medio: Quatre Carreres, Camins al Grau

Distritos que se están empezando a gentrificar: Jesús, Extramurs, Benimaclet (ligero aumento de caros)

5.5.4 Intento de PCA previo clustering 2018

Proporcionamos el HTML con el rmd:

<https://rpubs.com/mcmihala/1315144>

5.5.5 Matrices de distancias y estadístico de Hopkins 2018




Gráfico 5: Matriz de Distancias entre Distritos 2018.

Gracias al mapa de distancias podemos intuir visualmente antes de realizar algún método de clustering como se agruparán los distritos.

Varias "manchas" azul claro (distancia pequeña entre ellas) forman bloques compactos.

Cada bloque indica un conjunto de distritos con perfiles muy parecidos en las variables medias que empleamos. Entre esos bloques predominan valores cálidos ($> 10 - 12$), prueba de que esos grupos están bien separados: distritos del bloque A son bastante distintos de los del bloque B.

Proyectos II, integración y preparación de datos

Existe una estructura de agrupamiento clara: los bloques azulados sugieren 3-4 clústeres de distritos con características inmobiliarias semejantes.

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.5464	0.5629	0.5733	0.5768	0.5892	0.6225

Gráfico 6: Estadístico de Hopkins 2018.

Observamos el valor del estadístico de Hopkins que supera por poco el 0,5 , y su valor máximo llega a los 0,6395. Esto indica una débil o moderada tendencia al agrupamiento.

No es un valor extremadamente alto con el que podamos afirmar de manera segura que se forman clústeres muy bien definidos. No obstante, nos parece suficiente, y seguiremos con el clustering.




Gráfico 7: Matriz de Distancias entre Distritos 2025.

Sí, se aprecian indicios de la existencia de clusters, aunque no de forma perfectamente definida.

Hay subconjuntos de distritos que muestran mayor similitud entre ellos (zonas rojizas agrupadas), lo que justifica aplicar técnicas de clustering como k-means o clustering jerárquico para identificarlos formalmente.

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.5408	0.5533	0.5609	0.5677	0.5780	0.6221

Gráfico 8: Estadístico de Hopkins 2025.

Al igual que en 2018, no es un valor muy elevado, pero decidimos continuar con el clustering, hay ligera tendencia de agrupamiento.

5.5.6 *Clustering 2018*

Contamos con una explicación más detallada del método y sus elecciones en el .rmd del clustering.

También contamos con conclusiones más en profundidad, además de comparar diferencias y similitudes entre años:

<https://rpubs.com/mcmihala/1315148>

5.5.7 *Clustering 2025*

Contamos con una explicación más detallada del método y sus elecciones en el .rmd del clustering.

También contamos con conclusiones más en profundidad, además de comparar diferencias y similitudes entre años:

<https://rpubs.com/mcmihala/clust2025>

5.5.8 *Clústeres formados*

2018

Clúster 1: "Benimaclet", "Jesús"

Clúster 2: "Camins al Grau", "Campanar"

Clúster 3: "Ciutat Vella", "El Pla del Real", "Extramurs", "L'Eixample"

Clúster 4: "Algirós", "L'Olivereta", "Patraix"

Clúster 5: "Benicalap", "La Saïdia", "Poblats Marítims", "Quatre Carreres", "Rascanya"

2025

Clúster 1: "Ciutat Vella", "El Pla del Real", "Extramurs", "L'Eixample"

Clúster 2: "Benicalap", "Camins al Grau", "Campanar", "Patraix", "Poblats Marítims", "Quatre Carreres"

Clúster 3: "Algirós", "Benimaclet", "Jesús", "L'Olivereta"

Clúster 4: "La Saïdia", "Rascanya"

5.6 Objetivo 3

Para más detalles sobre los modelos, resultados y el código en R utilizado, proporcionamos un informe generado con RMarkdown en formato HTML:

<https://rpubs.com/cachupinto/1315184>

5.6.1 Correlación entre las variables




Gráfico 1: Correlación entre las variables para entrenar el modelo.

En resumen, como se puede observar en el Gráfico 1, el análisis de correlación confirma relaciones esperadas en el mercado inmobiliario, como la influencia positiva del tamaño y el número de dependencias en el precio, y la influencia negativa de la distancia a puntos de interés. Si bien se observan correlaciones altas entre algunas variables predictoras (especialmente CONSTRUCTEDAREA, ROOMNUMBER y BATHNUMBER), la decisión previa de no incluir variables directamente derivadas como priceByArea o RHabitacion_Banyo ya ha contribuido a mitigar problemas severos de multicolinealidad.

5.6.2 Modelos predictivos

Antes de hablar de los modelos utilizados vamos a introducir conceptos que utilizaremos para medir el desempeño de nuestros modelos.

- RMSE: Es la raíz cuadrada del promedio de los errores al cuadrado. Penaliza más los errores grandes. Cuanto más bajo mejor.

Proyectos II, integración y preparación de datos

- MAE: Es el promedio de los errores absolutos entre las predicciones y los valores reales. Menos sensible a valores extremos que el RMSE. Cuanto más bajo mejor.
- R^2 : Mide qué proporción de la variabilidad de los datos es explicada por el modelo, es decir, la calidad del ajuste del modelo. Cuanto más alto mejor.

Ahora pasamos a ver los resultados y los modelos que hemos usado:

Regresión Lineal: Es un modelo estadístico simple que asume una relación lineal entre las variables independientes y la variable dependiente. Es fácil de interpretar, pero limitado en su capacidad para capturar relaciones no lineales o interacciones complejas entre variables.

RMSE: 91516,08 - MAE: 52919,66 - R^2 : 0,7270535




Gráfico 2: Gráfico de dispersión para modelo de regresión lineal de la base de datos de 2018.




Gráfico 3: Importancia de las variables para modelo de regresión lineal de la base de datos de 2018.

Proyectos II, integración y preparación de datos

En el *Gráfico 2* observamos que la mayoría de los puntos se agrupan alrededor de la línea de ajuste perfecto, especialmente para los precios más bajos y medios (hasta aproximadamente 750,000 € - 1,000,000 €). Esto indica que el modelo tiene un desempeño razonable en este rango.

A medida que los precios reales aumentan (por encima de 1,000,000 €), notamos una mayor dispersión de los puntos y una tendencia del modelo a subestimar los precios más altos. Es decir, para las viviendas más caras, las predicciones tienden a ser inferiores a los valores reales. También hay algunos casos donde el modelo sobreestima. La heterocedasticidad (varianza no constante de los errores) podría ser un factor aquí, donde la variabilidad de las predicciones aumenta con el nivel del precio.

Para identificar qué variables tienen mayor influencia en las predicciones del modelo lineal, utilizamos la función *varImp* del paquete *caret*. El *Gráfico 3* muestra la importancia relativa de cada variable predictora en el modelo. El gráfico presenta las variables predictoras ordenadas de mayor a menor importancia (de arriba hacia abajo). La longitud de la barra azul claro indica la importancia relativa de cada variable, con la más influyente (en este caso, CONSTRUCTEDAREA) escalada a un valor de 100.

CONSTRUCTEDAREA (Superficie Construida): Es, con diferencia, la variable más importante en nuestro modelo lineal. Esto es coherente con la intuición y los análisis previos de correlación, indicando que el tamaño de la vivienda es el principal factor que el modelo utiliza para predecir el precio.

Variables de Distrito: La segunda variable más importante es DISTRITO.L'Eixample. Esto sugiere que pertenecer al distrito de L'Eixample (comparado con el distrito de referencia que se haya omitido en la codificación *dummy*) tiene un impacto significativo en el precio según el modelo. Otras variables de distrito como DISTRITO.Ciutat.Vella, DISTRITO.El.Pla.del.Real y DISTRITO.Camins.al.Grau también aparecen con una importancia considerable, aunque menor que L'Eixample. Esto resalta la relevancia de la ubicación geográfica a nivel de distrito.

Características de la Vivienda: ROOMNUMBER (Número de Habitaciones) y BATHNUMBER (Número de Baños) le siguen en importancia, lo cual es lógico, ya que, junto con la superficie, definen las características básicas de la vivienda. FLOORCLEAN (Número de Piso) también muestra una contribución relevante.

Como los resultados de la regresión lineal con el uso del logaritmo del precio y el percentil 95% no mejoran prácticamente el resultado, no mostramos las gráficas correspondientes.

Random Forest: Es un modelo de aprendizaje automático basado en la combinación de múltiples árboles de decisión. Ofrece alta precisión y es robusto frente al sobreajuste. Captura relaciones no lineales y funciona bien con datos complejos y con ruido. Gráficas y resultados mostrados previamente en la memoria. Vamos a mostrar los resultados del modelo inicial que no se muestran en la memoria:

RMSE: 67660.69 - MAE: 32814.38 - R²: 0.8508601

Proyectos II, integración y preparación de datos




Gráfico 4: Gráfico de dispersión para modelo XGBoost de la base de datos de 2018.




Gráfico 5: Importancia de las variables para modelo XGBoost de la base de datos de 2018.

El RMSE ha disminuido de aproximadamente 91,516 € a 67,661 €. Esto indica que, en promedio, los errores cuadráticos de predicción son considerablemente menores.

El MAE también ha disminuido notablemente, pasando de unos 52,920 € a 32,814 €. El error absoluto promedio de las predicciones se ha reducido en casi 20,000 €.

El R^2 ha aumentado de 0.727 a 0.851. Esto significa que el modelo Random Forest es capaz de explicar aproximadamente el 85.1% de la variabilidad en los precios de las viviendas del conjunto de prueba, una mejora de más del 12% en la varianza explicada en comparación con el modelo lineal.

Proyectos II, integración y preparación de datos

Como vemos en el *Gráfico 4*, los puntos (predicciones individuales) se muestran más agrupados alrededor de la línea roja discontinua (ajuste perfecto) en comparación con el gráfico del modelo de regresión lineal. Esto es especialmente notable en el rango de precios medios y altos.

Aunque todavía existe cierta dispersión, y el modelo puede subestimar o sobrestimar algunas viviendas, la tendencia general es una mejora en la precisión a lo largo de todo el espectro de precios.

Si observamos el *Gráfico 5*, de manera similar al modelo lineal, "CONSTRUCTEDAREA" emerge como la variable más importante para el modelo Random Forest, con una puntuación de importancia de 100. Esto reafirma que el tamaño de la vivienda es el factor individual más determinante del precio.

Variables de Distancia: A diferencia del modelo lineal donde los distritos específicos tenían una alta importancia justo después de la superficie, aquí las variables "DISTANCE_TO_CITY_CENTER" y "DISTANCE_TO_METRO" ocupan el segundo y tercer lugar, respectivamente, con puntuaciones de importancia alrededor de 83 y 78. Esto sugiere que el modelo Random Forest encuentra un fuerte poder predictivo en la proximidad a puntos clave de la ciudad, posiblemente capturando gradientes de precios más continuos que las categorías de distrito por sí solas.

Distritos Específicos: "DISTRITO.Benimaclet" aparece como el distrito individual más importante (cuarto en la general con una importancia cercana a 45), seguido de "DISTRITO.Camins.al.Grau" y "DISTRITO.Poblats.Marítims". Es notable que "DISTRITO.L.Eixample", que era la segunda variable más importante en el modelo lineal, ahora tiene una importancia mucho menor en el modelo Random Forest.

El problema de subestimación sistemática de los precios más altos, que era evidente en el modelo lineal, parece haberse mitigado considerablemente, aunque las viviendas de precios extremadamente altos (superiores a 1,500,000 € - 2,000,000 €) siguen presentando mayores errores, lo cual es común dada su escasez y variabilidad inherente.

XGBoost: Es un algoritmo de *boosting* que construye árboles de decisión de forma secuencial, corrigiendo los errores del modelo anterior. Es muy eficiente, rápido y suele ofrecer un alto rendimiento en tareas de predicción. Requiere ajuste de hiperparámetros para obtener su máximo potencial.

RMSE: 70004,63 - MAE: 34858,91 - R2: 0,8402484




Gráfico 6: Gráfico de dispersión para modelo XGBoost de la base de datos de 2018.




Gráfico7: Importancia de las variables para modelo XGBoost de la base de datos de 2018.

Al igual que con Random Forest, se observa en el *Gráfico 6* que los puntos se agrupan razonablemente bien alrededor de la línea de ajuste perfecto (roja discontinua).

La dispersión de los puntos, especialmente en los rangos de precios más altos, nos dará una indicación visual de su precisión y de si presenta patrones de error similares a los modelos anteriores.

Si nos fijamos en el *Gráfico 7* vemos que:

CONSTRUCTEDAREA: Una vez más, y de forma consistente con todos los modelos anteriores (Regresión Lineal y Random Forest), **CONSTRUCTEDAREA** es, con diferencia, la variable más importante para el modelo XGBoost, alcanzando el máximo

Proyectos II, integración y preparación de datos

de 100 en la escala de importancia. Esto subraya de manera inequívoca que el tamaño de la vivienda es el principal factor predictivo del precio.

DISTANCE TO CITY CENTER: Ocupa el segundo lugar con una importancia considerable, alrededor de 18-20. Esto es similar a lo que vimos con el modelo Random Forest, donde las variables de distancia continua también eran muy relevantes, aunque en Random Forest su importancia relativa era mayor en comparación con XGBoost.

BATHNUMBER: Esta variable aparece en tercer lugar, con una importancia alrededor de 10-12. En el modelo Random Forest, "BATHNUMBER" no estaba tan arriba en el ranking (estaba por debajo de "FLOORCLEAN" y varios distritos). Esto sugiere que XGBoost le da un peso relativamente mayor al número de baños que el Random Forest en esta configuración particular.

LightGBM: Similar a XGBoost, pero optimizado para velocidad y eficiencia en memoria. Es especialmente útil con grandes volúmenes de datos. Utiliza una técnica de crecimiento de árbol por hojas (leaf-wise), que puede mejorar la precisión en comparación con el crecimiento por niveles (level-wise).

RMSE: 72355,27 - MAE: 39014,97 - R^2 : 0,8293307




Gráfico 8: Gráfico de dispersión para modelo LightGBM de la base de datos de 2018.

Proyectos II, integración y preparación de datos




Gráfico 9: Importancia de las variables para modelo LightGBM de la base de datos de 2018.

El Gráfico 8 muestra una agrupación de puntos similar a la que vimos con XGBoost. Los puntos se distribuyen alrededor de la línea de ajuste perfecto.

La dispersión parece ser comparable a la de XGBoost. Al igual que con los otros modelos basados en árboles, parece manejar mejor la predicción en rangos de precios bajos y medios, con una mayor dispersión (errores más grandes) en los precios más altos. Visualmente, no parece haber una mejora drástica o un empeoramiento significativo en comparación con el gráfico de XGBoost.

Como se observa en el Gráfico 9 y en los ejemplos anteriores, las variables más importantes vuelven a ser “CONSTRUCTEDAREA”, “DISTANCE_TO_CITY_CENTER” y “BATHNUMBER”.

5.6.3 Modelos predictivos con clustering

A continuación, haremos uso de los clústeres previamente calculados para separar el municipio de Valencia y aplicar un modelo (sólo aplicaremos Random Forest por falta de tiempo y por ser el que mejor resultados nos ha dado anteriormente) a cada clúster para ver si de esta forma, es capaz de crear mejores predicciones con un error mayor. Los resultados que hemos obtenido son:

Clúster: cluster1 | RMSE: 33382.22 | MAE: 21486.05 | R^2 : 0.845
Clúster: cluster2 | RMSE: 82146.57 | MAE: 44865.74 | R^2 : 0.767
Clúster: cluster3 | RMSE: 115554.00 | MAE: 64770.64 | R^2 : 0.768
Clúster: cluster4 | RMSE: 40152.91 | MAE: 23122.47 | R^2 : 0.594
Clúster: cluster5 | RMSE: 41114.23 | MAE: 25644.19 | R^2 : 0.775

Clústeres 1, 4 y 5:

Tienen métricas de error (RMSE, MAE) más bajas y un R^2 aceptable o bueno frente al modelo global. Esto indica que la segmentación ha ayudado a captar particularidades de esos barrios y mejorar la predicción.

Proyectos II, integración y preparación de datos

Clústeres 2 y 3:

Presentan errores mucho más altos y un R^2 más bajo. Es probable que:

- Sean zonas más heterogéneas internamente (mucha variabilidad de precios, tipologías, etc.).
- Los datos de estos clústeres sean más escasos o tengan más *outliers*.
- El modelo no tenga suficientes datos/potencia predictiva para captar bien sus particularidades.

Debido a esto, no observamos mejoras sustanciales que nos hagan preferir estos modelos al que ya teníamos por lo que lo descartamos.

Vamos a probar a englobar en dos grandes clústeres que van a ver centro y periferia para así tener más datos en cada clúster y que el modelo pueda entrenarse mejor. Los clústeres son:

Clúster 1 -> Ciutat Vella, L'Eixample, El Pla del Real, Extramurs

Clúster 2 -> Poblat Marítims, Benicalap, Rascanya, La Saïdia, Quatre Carreres, Benimaclet, Jesús, Camins al Grau, Patraix, Campanar, Algirós, L'Olivereta

Clúster: Centro | RMSE: 105834.78 | MAE: 63127.57 | R^2 : 0.796

Clúster: Periferia | RMSE: 47913.14 | MAE: 29731.10 | R^2 : 0.752




Gráfico 10: Gráfico de dispersión para modelo Random Forest de la base de datos de 2018 del clúster con los distritos del centro.

Proyectos II, integración y preparación de datos




Gráfico 11: Gráfico de dispersión para modelo Random Forest de la base de datos de 2018 del clúster con los distritos de la periferia.

Los resultados nos muestran que el modelo por clústeres (Centro y Periferia) no mejora el error respecto al modelo global, especialmente en el clúster Centro como vemos en el *Gráfico 10*. ¿Por qué los resultados no mejoran?

Tamaño de muestra reducido

Al dividir en dos clústeres, cada modelo se entrena con menos datos, especialmente en el centro (barrios como Ciutat Vella, L'Eixample, etc. tienen menos viviendas que toda la ciudad). Esto afecta la capacidad del Random Forest de generalizar y aumenta el error, sobre todo en presencia de muchos *outliers* o alta dispersión de precios.

Mayor heterogeneidad interna en el "Centro"

El centro suele tener una mayor variedad de tipos de vivienda y precios (pisos de lujo, viviendas antiguas, áticos, etc.), lo que complica la predicción. Como no tenemos suficientes variables que expliquen bien esa variedad, el modelo lo sufre.

Presencia de *outliers*

En el gráfico se ve que hay bastantes puntos alejados de la diagonal, sobre todo para precios altos. El centro suele tener propiedades muy caras que el modelo no predice bien.


Menos capacidad para aprender patrones generales

Cuando entrenamos el modelo global, puede aprender relaciones que son válidas para toda la ciudad (por ejemplo, el tamaño, el estado, etc.). Al segmentar demasiado, podemos perder esa generalidad.

5.7 Objetivo 4

Rmd completo: <https://rpubs.com/roberttorres/1315187>

5.7.1 IPV



Evolución anual IPV 2008-2024